AI MAT

MATEMATIKKEN BAG MAGIEN

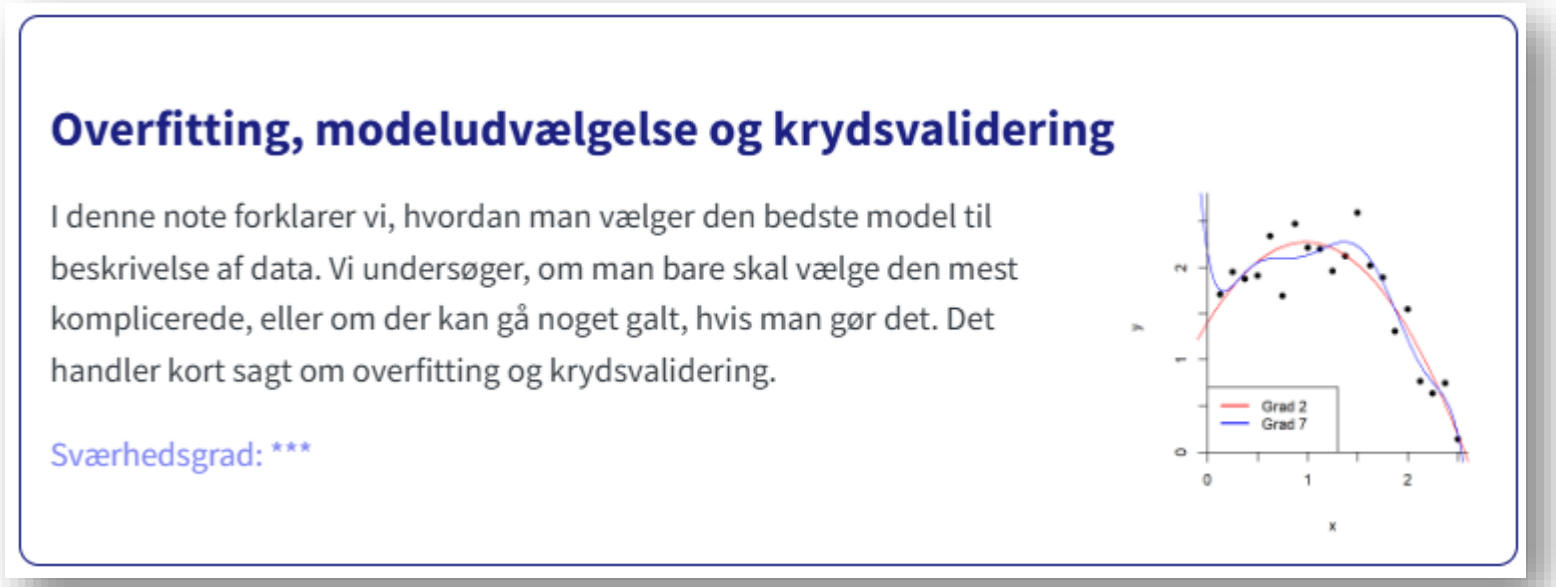
Ege Rubak / Institut for matematiske fag, AAU
Malene Cramer Engebjerg / Aalborg Katedralskole

Program for denne del

- Kunstige neuroner – herunder
  - Overfitting og modeludvælgelse
  - Trænings- og testdata
  - Krydsvalidering
  - Slow learning

Overfitting, modeludvælgelse og krydsvalidering

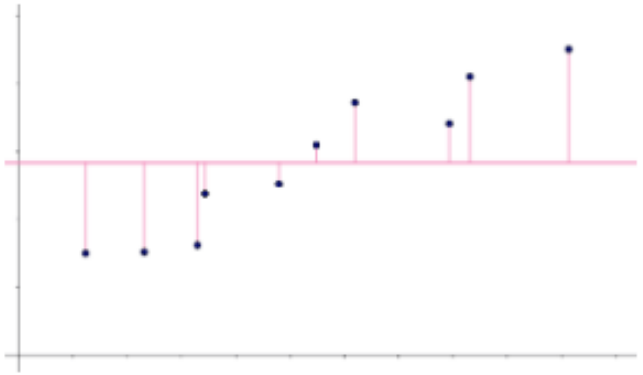
- Vi har en hel note om emnet (ift. regression):



Mål for en models nøjagtighed

Mål for en models nøjagtighed

Når man bruger en model (det kan være en kunstig neuron, et neuralt netværk, logistisk regression eller noget helt fjerde), så vil man altid være interesseret i at sige noget om, hvor god modellen er. Denne note handler om præcis det: Forskellige mål som kan bruges til at vurdere en models nøjagtighed.



Sværhedsgrad: **

Mål for en models nøjagtighed

Modeller til klassifikation

- Confusion matrix

	Forudsagt A	Forudsagt B	I alt
Faktisk A	84	16	100
Faktisk B	20	80	100
I alt	105	95	200

- Klassifikationsnøjagtighed (CA)

Den andel af data, som klassificeres korrekt.

Modeller til prædiktion af numeriske værdier

- R^2-værdien
- Root Mean Squared Error (RMSE)

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

- Mean Absolute Error (MAE)

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

Kunstig neuron: Binær klassifikation

En høj klassifikationsnøjagtighed er ikke altid lykken!

	Forudsagt A	Forudsagt B	I alt
Faktisk A	84	16	100
Faktisk B	20	80	100
I alt	105	95	200

Klassifikationsnøjagtighed på

$$\frac{84 + 80}{200} = 82\%$$

Men hvordan prædikterer modellen på nye og ukendte data?

Når det naive gæt er lige så godt...

	Klassificeret som A	Klassificeret som B	I alt
Faktisk A	132	32	164
Faktisk B	4	32	36
I alt	136	64	200

Det naive gæt er lige så godt!

Igen klassifikationsnøjagtighed på

$$\frac{132 + 32}{200} = 82\%$$

Hvordan klarer modellen sig på nye data?

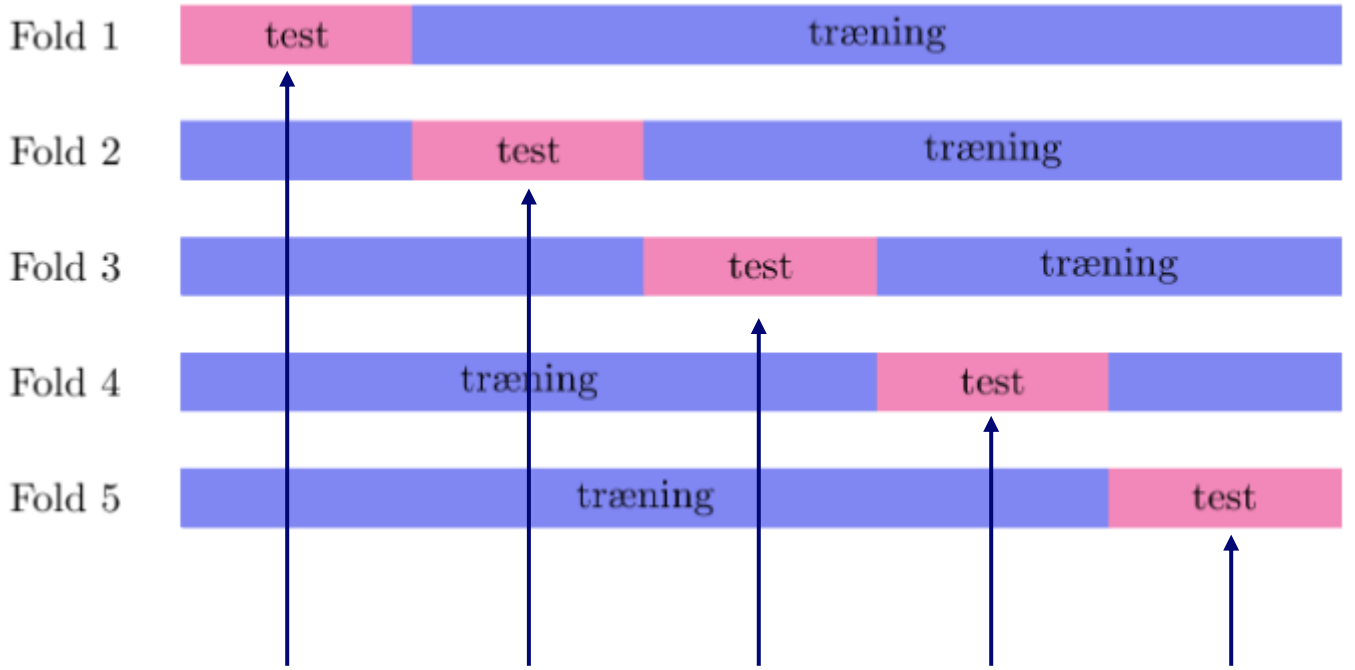
- Træningsdata: fx 80%
- Testdata: fx 20%



Beregn outputværdier, confusion matrix og CA

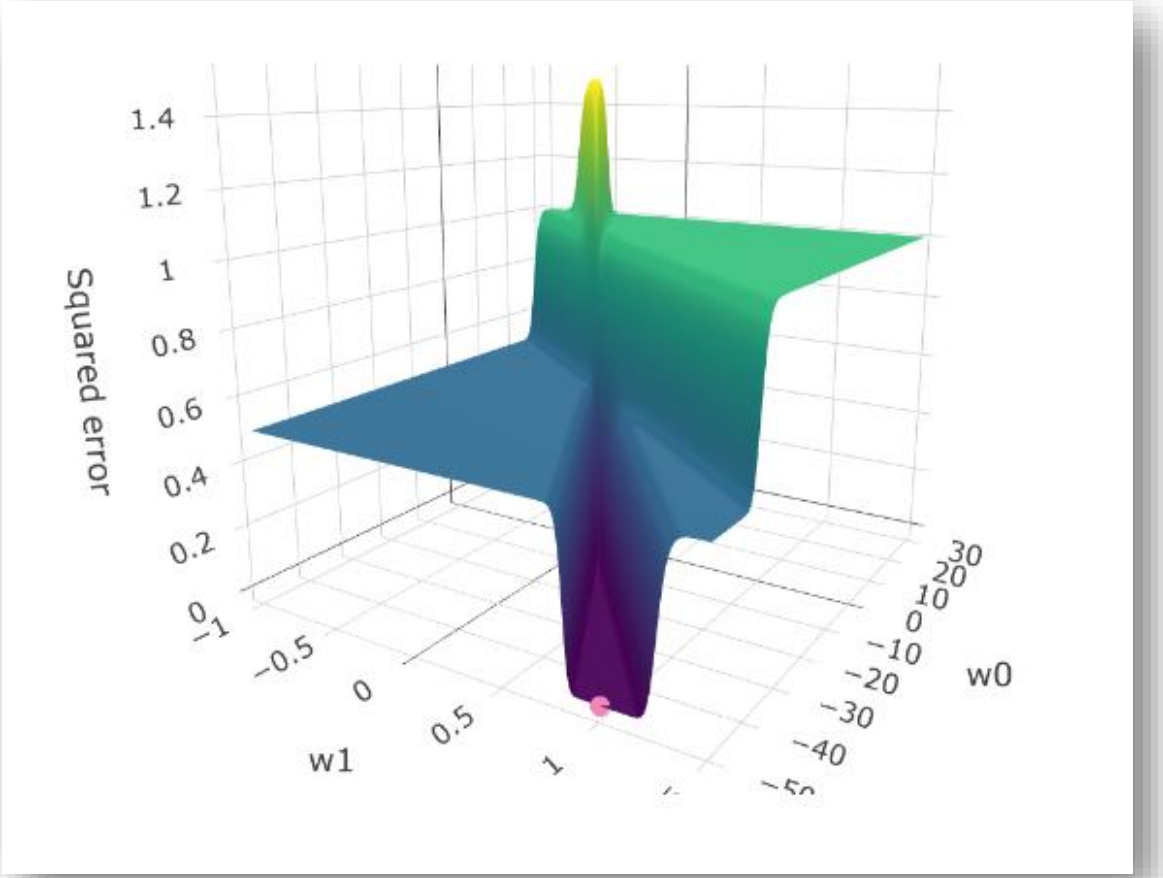
Bestem værdier af vægtene vha. gradientnedstigning

Krydsvalidering

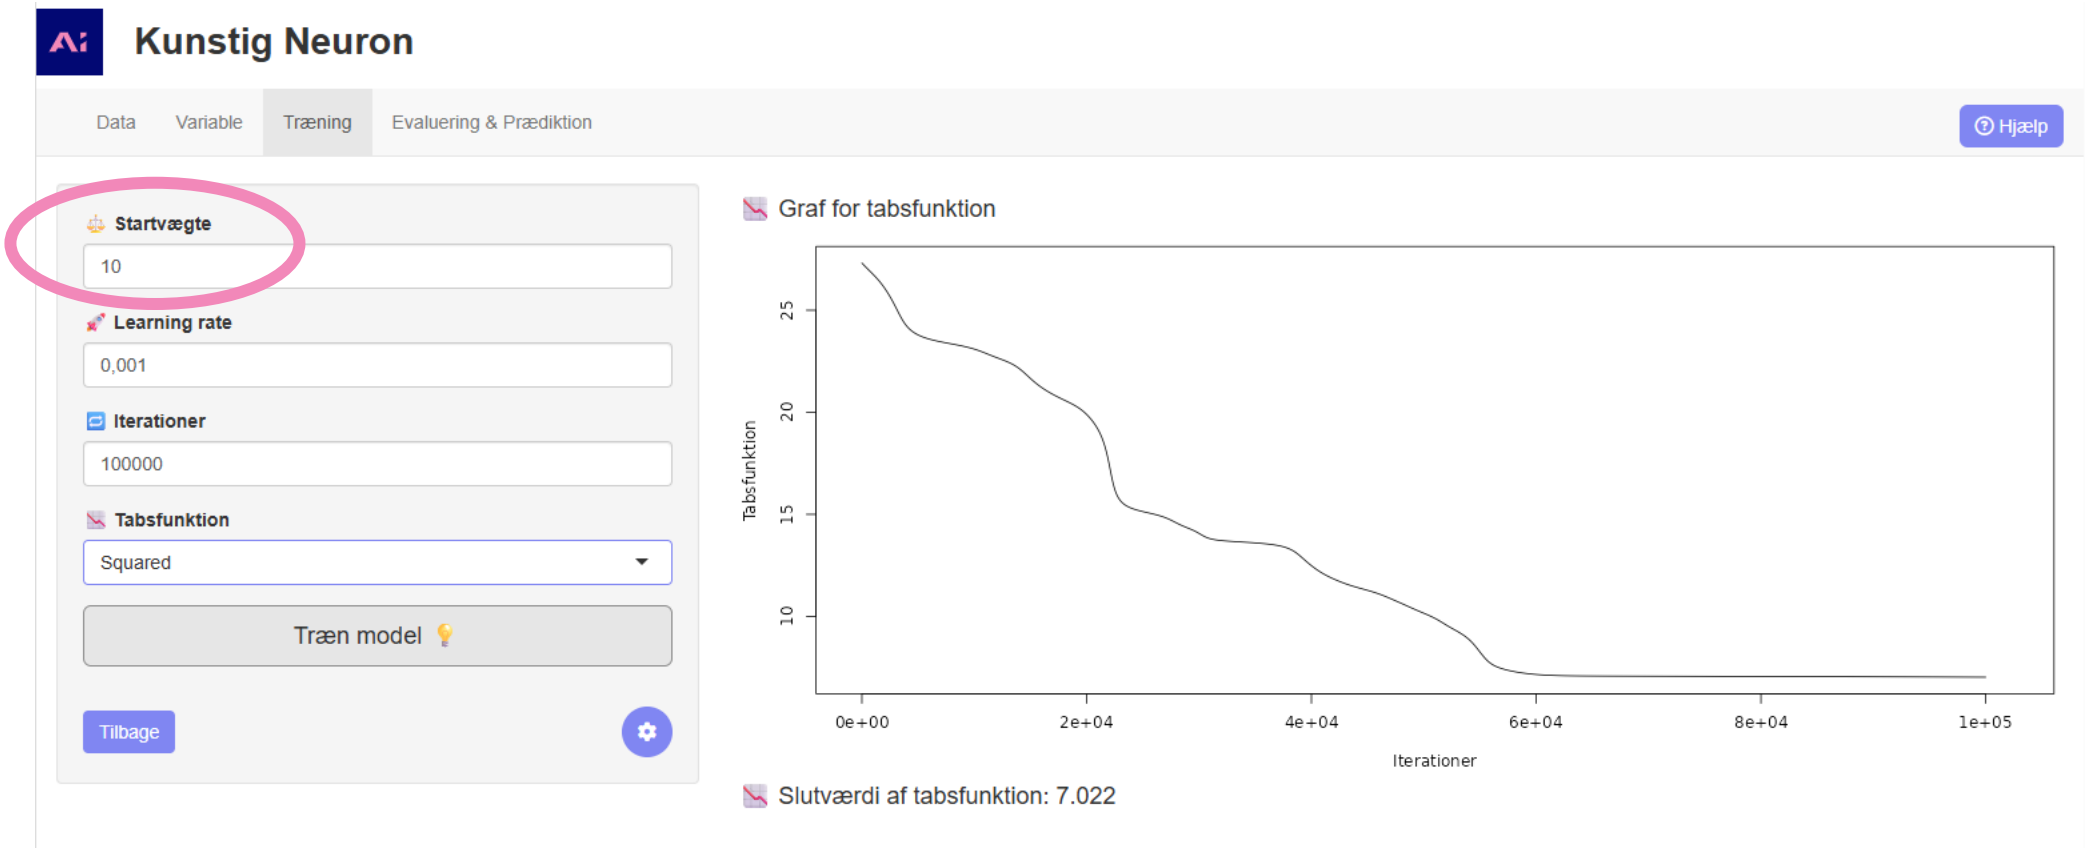


Alle træningseksempler indgår præcist én gang i et testdatasæt – vi kan derfor beregn outputværdier, confusion matrix og CA for det samlede datasæt

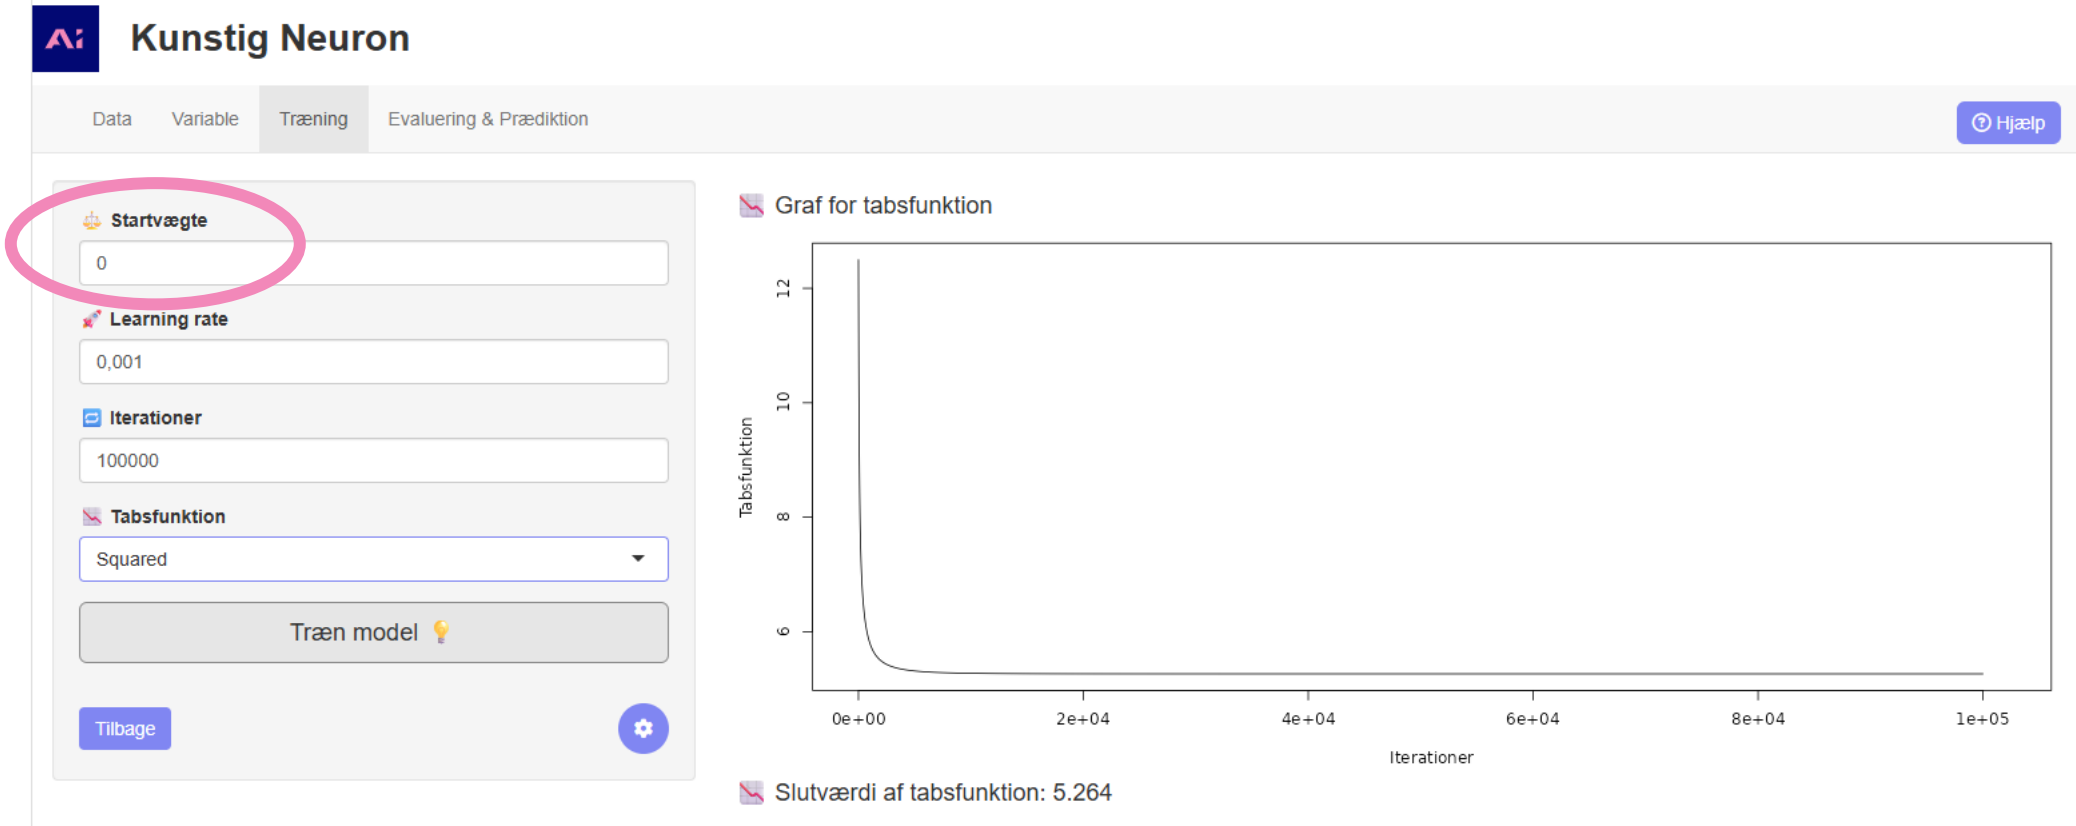
Problemer med *squared error* tabsfunktionen



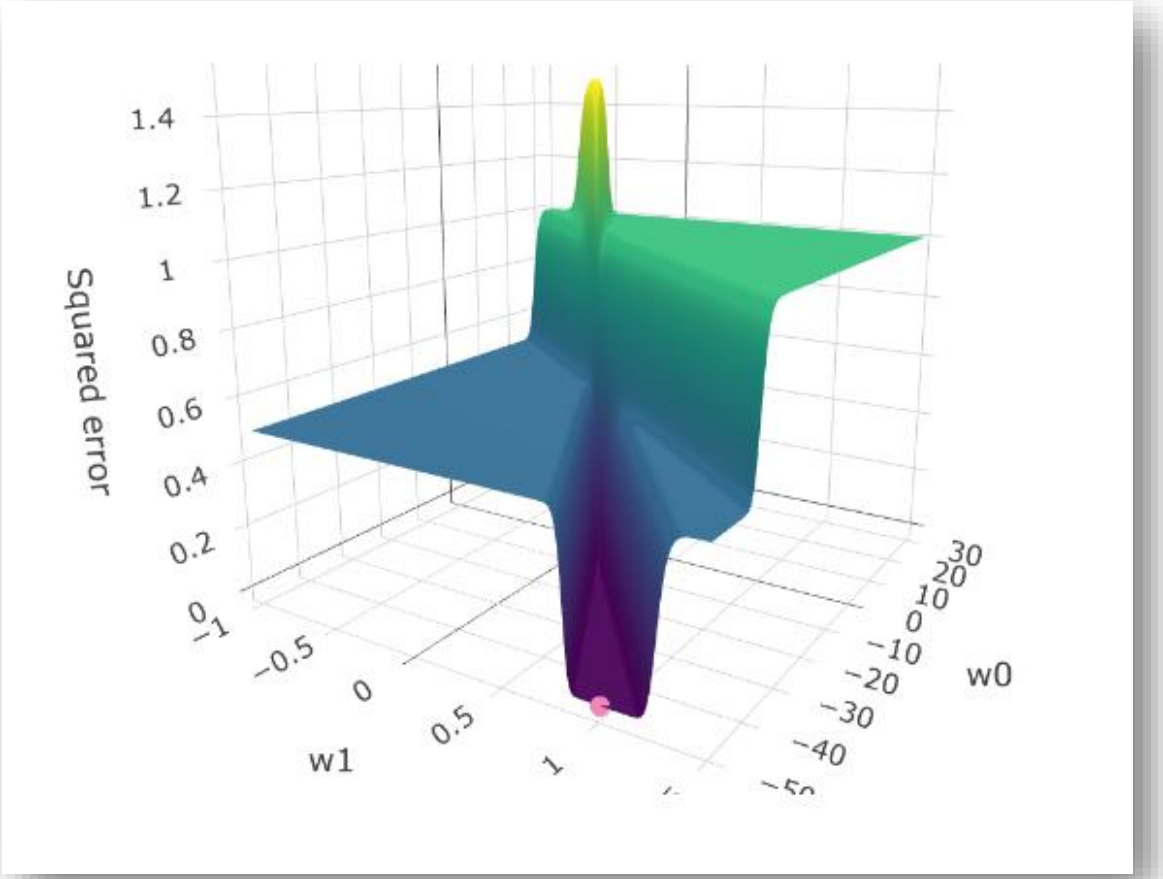
Slow learning



Not so slow


Kunstig Neuron
Data
Variable
Træning
Evaluering & Prædiktion
Hjælp
Startvægte
0
Learning rate
0,001
Iterationer
100000
Tabsfunktion
Squared
Træn model
Tilbage
Graf for tabsfunktion
Tabsfunktion
6
8
10
12
0e+00
2e+04
4e+04
6e+04
8e+04
1e+05
Iterationer
Slutværdi af tabsfunktion: 5.264

Det kommer an på, hvor vi starter gradientnedstigningen



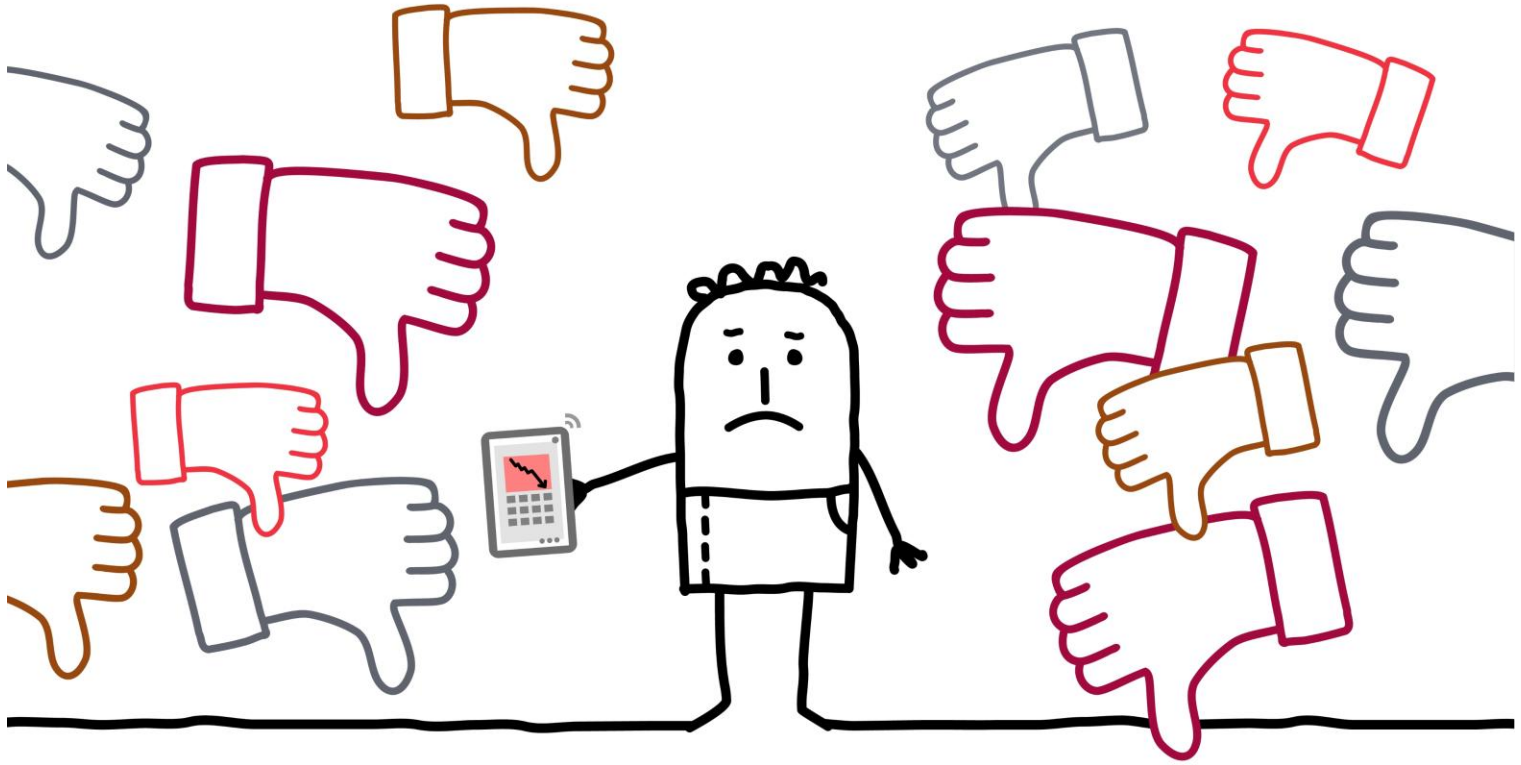
Slow learning...

... opstår når neuronen er fejlagtigt mættet!

$$w_i^{(ny)} \leftarrow w_i + \eta \cdot \sum_{m=1}^{M} \left(t^{(m)} - o^{(m)}\right) \cdot o^{(m)} \cdot \left(1 - o^{(m)}\right) \cdot x_i^{(m)}$$



Squared error og sigmoid er et dårligt match!



Egenskaber ved en tabsfunktion

Tabsfunktioner

I langt de fleste tilfælde sker træning af AI modeller ved at minimere en tabsfunktion. Lidt løst sagt kan man sige, at en tabsfunktion måler, hvor god en AI model er til at forudsige det, vi gerne vil have den til at sige noget om. I denne note forklarer vi, hvordan tabsfunktioner kan se ud, og hvad træningsdata er for en størrelse.



Sværhedsgrad: ***

Egenskaber ved en tabsfunktion E

- Tabsfunktionen skal være positiv eller 0: $E \geq 0$ (vi vil ikke operere med negative fejl).
- Hvis AI modellen er god til at prædiktere, skal E være tæt på 0, mens hvis AI modellen er dårlig til at prædiktere, skal E være langt væk fra 0.

Det opfylder squared error tabsfunktionen

$$E(w_0, w_1, \dots, w_n)$$

$$= \frac{1}{2} \sum_{m=1}^{M} \left(t^{(m)} - \sigma \left(w_0 + w_1 \cdot x_1^{(m)} + \cdots + w_n \cdot x_n^{(m)} \right) \right)^2$$

$$= \frac{1}{2} \sum_{m=1}^{M} \left(t^{(m)} - o^{(m)} \right)^2$$

En anden tabsfunktion: Cross-entropy

$$E(w_0, w_1, \dots, w_n) = -\sum_{m=1}^{M} \left(t^{(m)} \cdot \ln\left(o^{(m)}\right) + \left(1 - t^{(m)}\right) \cdot \ln\left(1 - o^{(m)}\right) \right)$$

hvor

$$o^{(m)} = \sigma\left(w_0 + w_1 \cdot x_1^{(m)} + \cdots + w_n \cdot x_n^{(m)}\right)$$

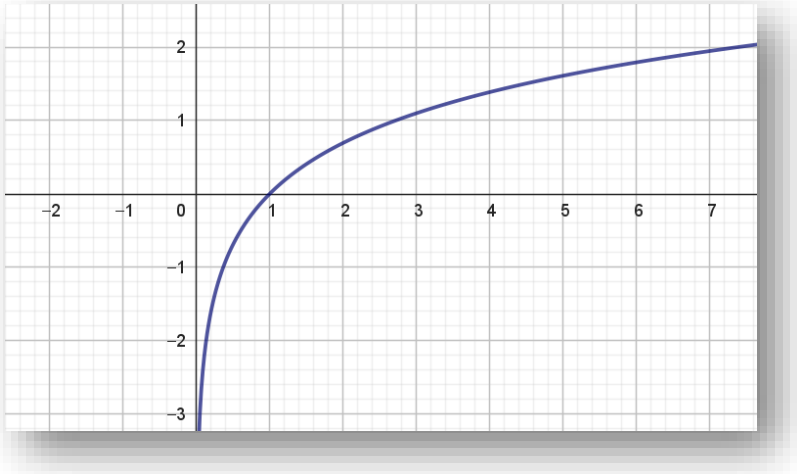
Svarer til minus log-likelihood funktionen fra logistisk regression.

Cross-entropy tabsfunktionen

$$E(w_0, w_1, \dots, w_n) = -\sum_{m=1}^{M} \left(t^{(m)} \cdot \ln\left(o^{(m)}\right) + \left(1 - t^{(m)}\right) \cdot \ln\left(1 - o^{(m)}\right)\right)$$

Hvis:

- $t^{(m)} = 0$: $\left(t^{(m)} \cdot \ln\left(o^{(m)}\right) + \left(1 - t^{(m)}\right) \cdot \ln\left(1 - o^{(m)}\right)\right) = \ln\left(1 - o^{(m)}\right)$
- $t^{(m)} = 1$: $\left(t^{(m)} \cdot \ln\left(o^{(m)}\right) + \left(1 - t^{(m)}\right) \cdot \ln\left(1 - o^{(m)}\right)\right) = \ln\left(o^{(m)}\right)$



Forskel på opdateringsregler

Squared error

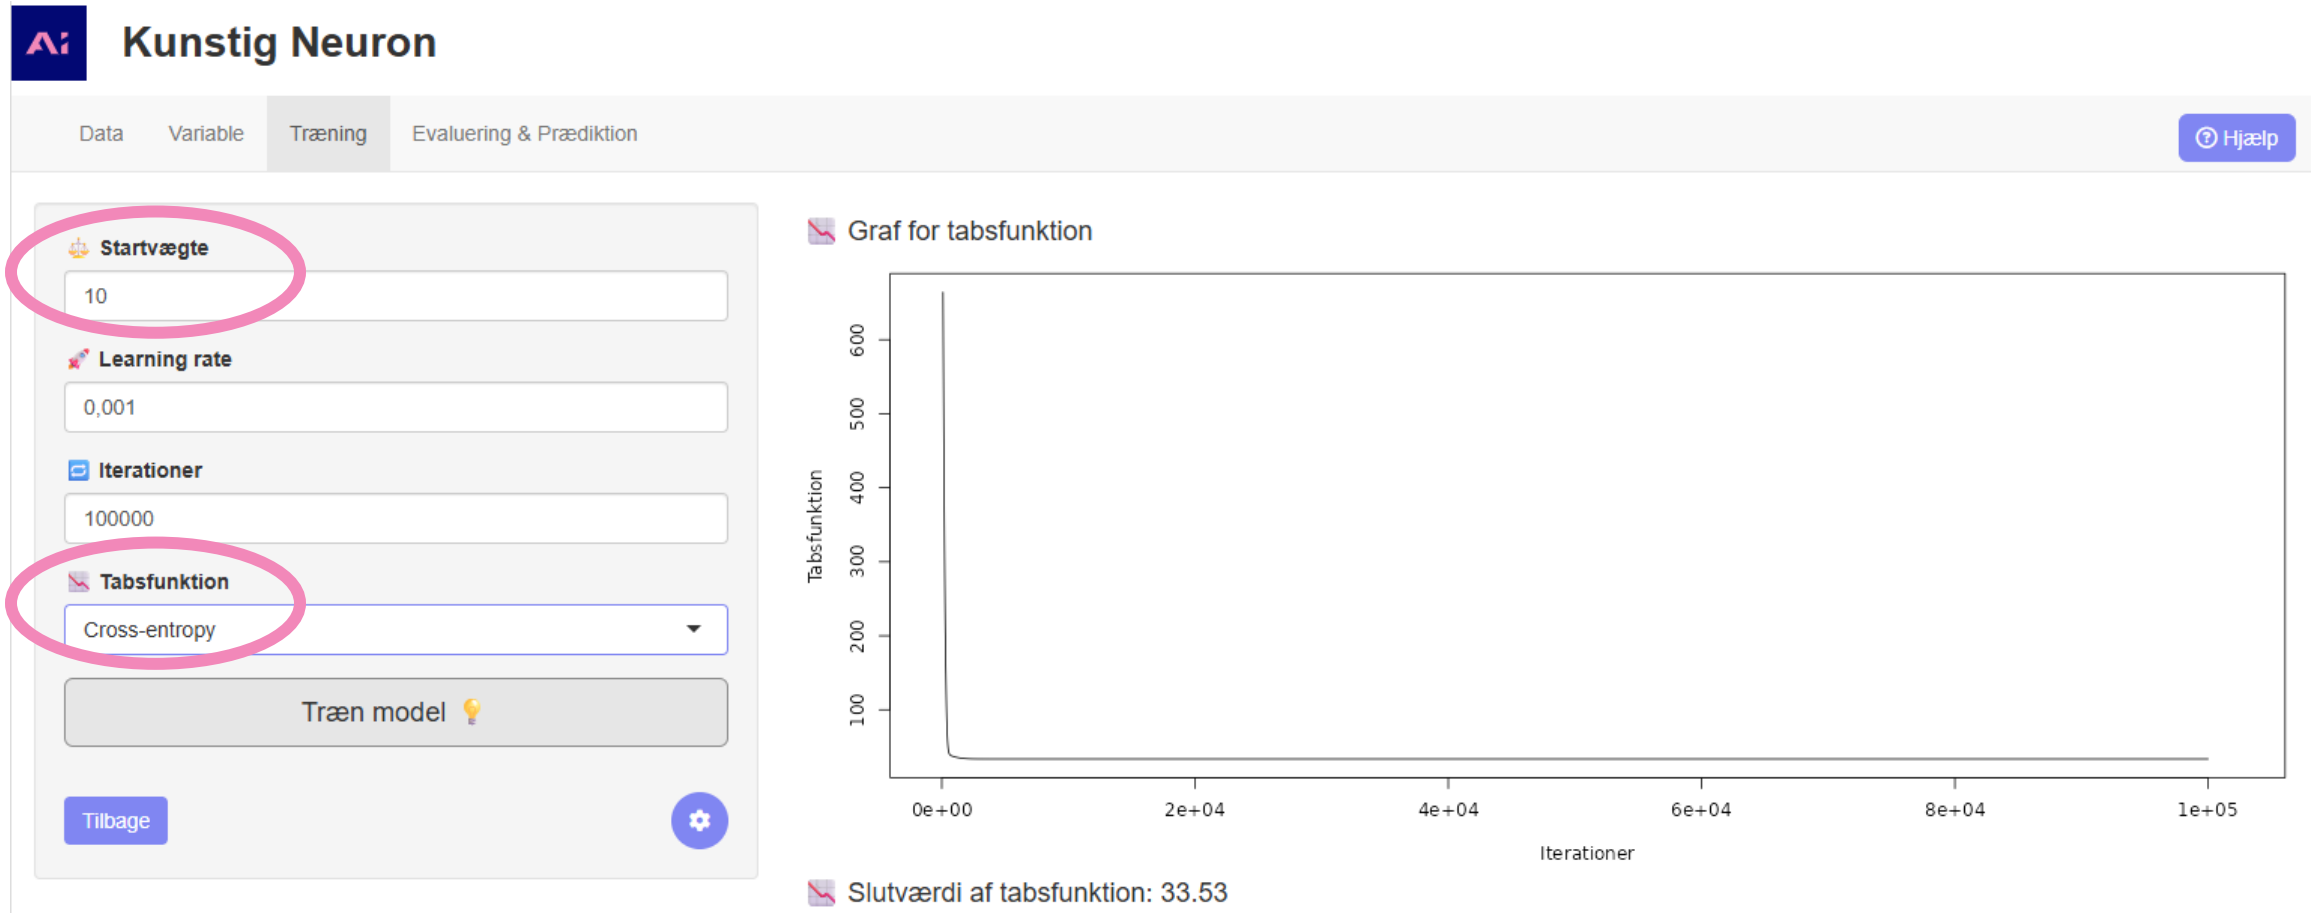
$$w_i^{(ny)} \leftarrow w_i + \eta \cdot \sum_{m=1}^{M} \left(t^{(m)} - o^{(m)}\right) \cdot o^{(m)} \cdot \left(1 - o^{(m)}\right) \cdot x_i^{(m)}$$

Cross-entropy

$$w_i^{(ny)} \leftarrow w_i + \eta \cdot \sum_{m=1}^{M} \left(t^{(m)} - o^{(m)}\right) \cdot x_i^{(m)}$$

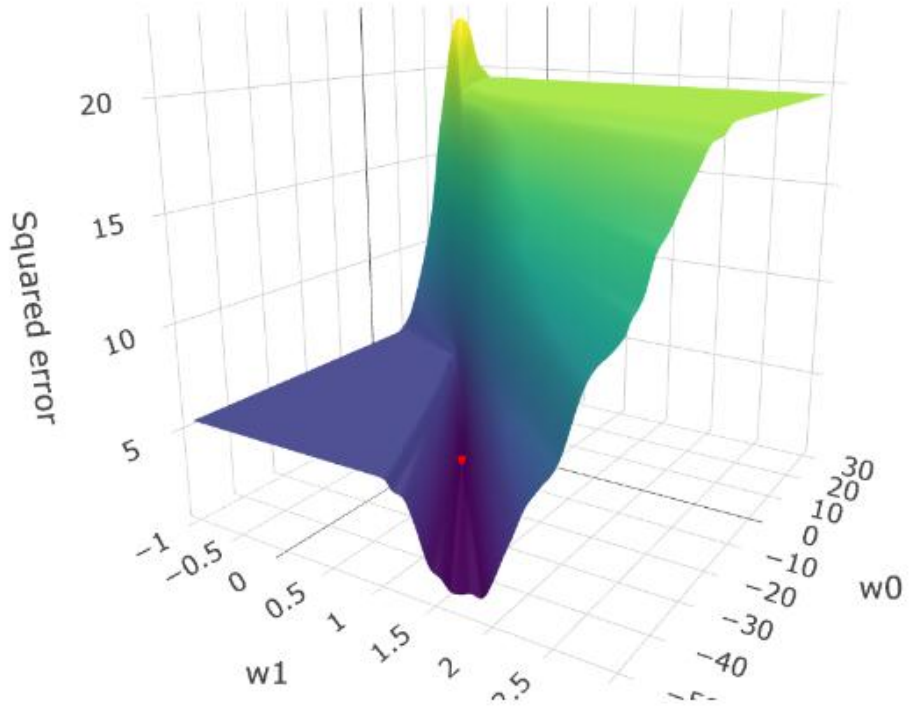
Bemærk, at faktoren $o^{(m)} \cdot \left(1 - o^{(m)}\right)$ er ude!

Træning med cross-entropy

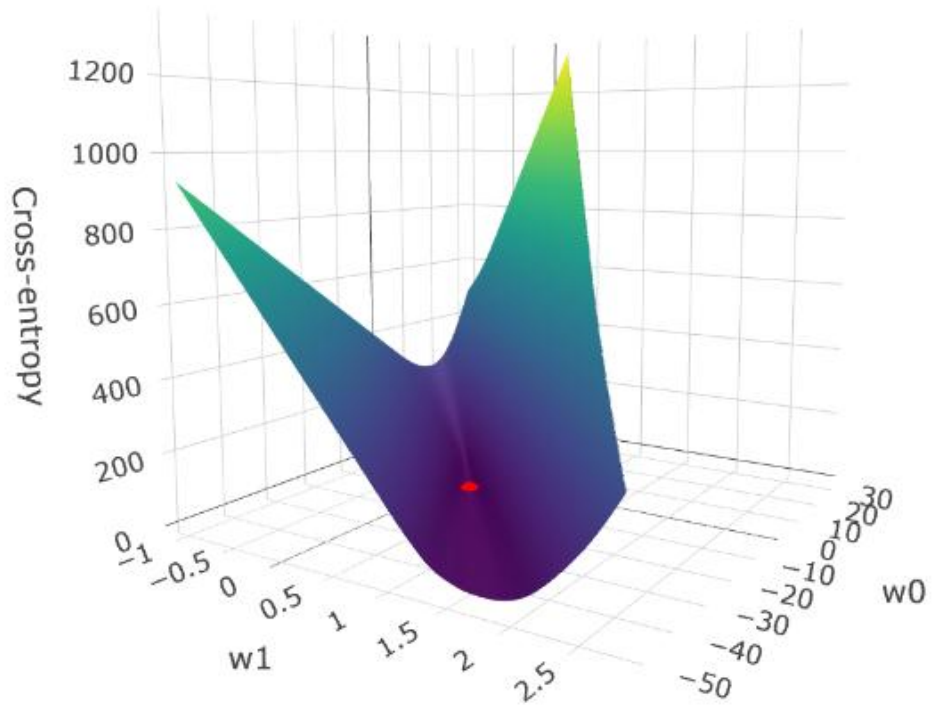


Sammenligning af grafer (én feature)

Squared error



Cross-entropy



Hands-on (vælg selv)

